

匠芯智修 ——面向汽车总装与数控机床设备的智能检修系统

2026 年 8 月

目录

第一章 引言	1
1.1 项目背景与意义.....	1
1.2 系统目标与核心功能.....	3
1.3 目标用户与应用前景.....	6
第二章 功能需求	9
2.1 多模态智能检修问答模块	9
2.2 设备知识图谱模块.....	10
2.3 动态 SOP 作业指引模块	11
2.4 检修工单归档与管理模块	12
2.5 手册与知识库管理模块.....	12
2.6 用户与权限管理模块.....	13
2.7 系统运维监控模块.....	14
2.8 移动端便捷支持.....	16
2.9 国产化适配与部署支持	17
第三章 非功能需求	18
3.1 性能需求	18
3.2 可用性需求	19
3.3 可靠性需求	20
3.4 可扩展性需求	21

第一章 引言

1.1 项目背景与意义

当前，我国正处于制造业向高端化、智能化、绿色化转型升级的关键阶段，国家“十四五”智能制造发展规划明确提出，要深化新一代信息技术与制造业融合发展，全面提升工业生产、运维、管理全流程的数字化智能化水平。2024 年启动的“人工智能 + 制造业”行动进一步强调，要推动大模型、知识图谱等人工智能技术在设备运维、故障诊断、工艺优化等场景的深度落地，以新质生产力赋能传统制造业升级。工业设备作为制造业的核心生产载体，其运维检修效率直接决定了生产线的稼动率与生产安全，是企业降本增效、提质升级的关键环节。



图 1 政策支持

在传统检修场景中，设备故障处理仍高度依赖维修人员个人经验。项目团队在前期企业调研与设备现场观察中发现，维修手册、报警代

码、历史维修记录和技术人员经验通常分散在不同载体中，形成明显的知识孤岛；面对复杂故障时，一线人员往往需要反复查阅手册、检索历史资料或向资深人员请教，知识获取链路较长。对于经验不足的新员工而言，同一故障还可能因检修人员知识水平不同而形成完全不同的排查路径，难以形成统一、可复用的标准化诊断流程。旧版项目调研已经将知识分散、低效检索、经验依赖和标准化不足确定为现场检修的主要问题。项目前期实地调研也进一步发现，检修知识“孤岛化”、新人上手慢以及故障响应滞后等问题普遍存在。

与此同时，工业现场故障信息本身具有明显的多模态特征。检修人员面对的往往不仅是一段故障描述，还包括数控系统报警界面、报警代码、设备铭牌、部件损坏照片以及维修文档等信息。仅依靠传统关键词检索难以同时理解这些不同形式的信息，而直接使用通用大语言模型又容易面临企业专业知识覆盖不足、答案依据不明确以及结果难以追溯等问题。

近年来，大语言模型、检索增强生成、视觉大模型、知识图谱和智能体技术的发展，为解决上述问题提供了新的技术基础。本项目在此基础上构建面向汽车总装与数控机床设备的智能检修系统，将维修手册、维修案例和结构化故障知识组织为统一知识底座，并将文本描述与故障图片共同纳入检索和诊断过程。当前系统已经支持文本、设备型号以及故障图片联合输入，图片首先由视觉模型解析，再与文本

信息共同参与语义检索和故障定位。

与单纯的“智能问答工具”相比，本项目进一步将智能能力贯穿故障处理全过程：从用户描述故障开始，系统完成知识检索、故障分析与诊断决策，随后生成并管理标准化 SOP 作业步骤，在维修完成后形成维修记录，并将经过确认的案例重新沉淀至知识体系中，逐步形成“故障输入—知识检索—智能诊断—作业执行—维修归档—知识回流”的闭环业务流程。



图 2、图 3 实地考察

1.2 系统目标与核心功能

本系统定位为一套面向汽车总装与数控机床设备的智能检修系统。系统以企业维修知识为基础，以检索增强生成和知识图谱为知识支撑，以大语言模型与 LangGraph Agent 为智能决策核心，将故障诊断、知识检索、SOP 作业执行、维修记录以及知识更新等环节进行统一组织，为一线维修人员和运维管理人员提供贯穿设备故障处理全过程的智能化支持。

从系统架构来看，当前作品采用前后端分离方式实现。前端基于 Vue 3、Pinia、Element Plus 等技术构建，负责多轮会话、故障输入、SOP 展示、维修报告和知识图谱等交互；后端采用 FastAPI、LangChain、SQLAlchemy 与 MySQL 构建，负责智能问答、Agent 调度、知识同步、图谱查询、用户权限与系统监控等核心业务。

在最新版本中，系统主要形成以下几类核心能力。

首先是多模态故障理解与融合检索能力。用户既可以通过自然语言描述设备故障，也可以上传现场故障图片，并结合设备型号进行诊断。视觉模型负责识别图片中的报警信息和故障特征，随后系统将文本与视觉分析结果共同送入知识检索链路。在知识检索层面，系统并非采用单一向量搜索，而是将语义向量检索、关键词精准匹配与知识图谱关联扩展相结合，使自然语言描述、报警代码以及故障关联知识能够共同参与候选知识召回。

其次是 RAG 与智能体协同的故障诊断能力。系统当前提供 RAG 直接诊断和 LangGraph Agent 两类执行方式。对于标准化程度较高的故障，可通过 RAG 检索企业知识库后直接生成诊断结果；对于复杂故障，则由 Agent 根据任务状态自主调用维修案例检索、维修手册检索、MySQL 知识图谱查询以及 SOP 管理等工具完成多阶段排障。在 Agent 内部，系统优先检索已有维修案例，在存在高匹配历史经

验时优先复用已验证方案；当历史案例不足时，再联合维修手册与知识图谱完成原因和解决方案推导，从而实现由“查询资料”向“辅助诊断决策”的能力提升。

第三是动态知识库与知识图谱构建能力。系统能够对维修手册进行解析和同步，并同时更新全文知识库、向量索引和知识图谱。当前知识同步流程可将 PDF、DOCX 等维修资料解析为检索单元，同时建立向量索引，并通过三元组抽取将故障、原因和解决方案等结构化关系写入 MySQL 图谱。对于维修过程中形成的新案例和人工修正内容，系统同样提供知识回流机制，经审核或同步后的有效知识能够重新进入后续检索链路，使知识库能够随企业维修实践持续更新。

第四是可控的 SOP 标准化作业能力。系统能够根据诊断结果生成检修步骤，并以会话为单位保存 SOP 状态。与普通大模型在多轮交流中反复修改操作步骤不同，当前系统在首版有效 SOP 生成后对步骤结构进行冻结，后续主要更新步骤执行状态和备注，避免同一检修任务中作业流程随模型回答发生无序变化。SOP 数据通过 MySQL 持久化保存，并与对应会话进行隔离，实现检修过程的可执行、可跟踪和可回溯。

第五是维修业务闭环与企业级管理能力。在故障处理完成后，一线人员可以形成维修报告和维修记录，历史记录又可以作为新的维修

案例参与后续故障诊断，构成“诊断—执行—归档—再利用”的知识循环。管理端则进一步提供用户及权限、手册管理、维修案例、检修记录、知识图谱和系统监控等功能，使系统既能服务现场故障处理，也能够承担企业维修知识资产管理任务。

因此，本项目的目标已经从旧版文档中“快速查询维修资料”的工具型定位，进一步提升为以企业知识为基础、以多模态理解为入口、以 RAG 与 Agent 为诊断核心、以 SOP 和维修记录为业务闭环的智能检修作业平台。旧版文档提出的“知识检索、智能诊断、作业指引、沉淀归档”总体方向仍然成立，但需要按照当前作品的实际技术实现进行上述升级。

1.3 目标用户与应用前景

结合当前系统功能与实际业务流程，本项目主要面向三类用户。

第一类为一线设备检修人员。该类用户是系统最直接的使用群体，可在设备发生异常后通过文字、图片和设备型号描述现场问题，由系统辅助完成相关维修资料检索、故障原因分析和解决方案生成，并在右侧 SOP 作业流程的辅助下逐步完成排查和维修。对于经验不足的维修人员，多模态输入能够降低专业故障描述门槛，案例与维修手册联合检索也能够减少依赖个人记忆查找资料的过程。

第二类为维修主管、技术负责人及知识运营人员。该类用户不仅

需要查看单次故障处理结果，还需要对企业长期积累的维修经验进行管理。系统提供维修记录、维修案例、设备手册及知识图谱等统一管理入口，可将分散在个人经验和文档中的维修知识逐渐转化为可检索、可关联和可重复利用的数字知识资产。

第三类为系统管理员与企业信息化管理人员。系统具有用户管理、权限组管理、知识库同步、模型及服务配置和系统运行监控等能力，可对不同岗位配置相应访问和操作权限。后端基于 JWT 完成用户身份认证，并通过权限体系控制知识管理和系统管理操作，为企业多人协同使用提供基础安全保障。

在应用价值层面，本项目主要解决三个层次的问题：在现场作业层面，将分散查询、人工判断和自由式操作整合为统一的智能诊断与 SOP 作业过程；在知识管理层面，将维修手册、历史案例和维修结果持续转化为可复用知识；在企业管理层面，通过用户权限、维修记录、知识图谱和系统监控等功能建立可追溯的检修业务数据链路。由此，维修人员每完成一次有效故障处理，都可以为企业知识体系增加新的可复用经验，使系统能力能够伴随实际使用持续积累。

在部署方面，系统同时考虑了国产化环境的适配需求。当前知识图谱前端已经调整为 Vue + ECharts 本地依赖渲染方式，不再依赖 iframe 加载后端静态页面，也不依赖 CDN 版 ECharts，从而降低龙

芯环境下由于外部网络和架构差异带来的兼容风险。项目同时提供 LoongArch 环境下的前后端运行方案，前端可直接使用原生 Node.js 环境，后端基于 Python 3.13、FastAPI 以及 MySQL 等组件运行。

与依赖固定 x86 容器镜像的部署方式相比，当前项目优先采用目标系统的原生运行环境和本地依赖，并对知识图谱等关键前端功能进行了针对性的架构调整。这一设计增强了系统在国产处理器与国产操作系统环境中的可部署性，也使项目具备进一步面向制造企业实际基础设施环境落地的工程基础。

总体来看，“匠芯智修”已经形成了从多模态故障输入、企业知识检索、智能诊断决策、标准化 SOP 执行，到维修记录归档和知识持续更新的完整业务链路。项目的核心价值不仅体现在对单次故障的辅助处理，更体现在将企业长期分散的维修知识逐步沉淀为可搜索、可推理、可传承的数字知识资产，并通过持续的维修实践实现知识体系的迭代更新。

第二章 功能需求

2.1 多模态故障诊断与智能问答

多模态故障诊断与智能问答是系统面向一线检修人员的核心交互入口。针对数控设备故障描述形式多样、现场信息难以仅通过文字完整表达的问题，系统支持自然语言、设备型号与故障图片等信息联合输入。用户可直接描述报警现象、设备异常或维修需求，也可上传现场故障图片，使不同类型的故障信息统一进入后续知识检索与诊断流程，降低检修人员组织专业描述的使用门槛。

系统接收用户问题后，将输入信息与企业维修知识库进行匹配，并结合相关维修手册、历史维修案例及设备知识生成诊断回答。对于需要进一步确认的复杂问题，用户可在同一检修会话中持续补充故障现象和操作结果，系统保存对应会话上下文，实现面向单次维修任务的连续交互。不同检修任务之间相互独立，便于一线人员对历史故障处理过程进行回顾和复盘。

在结果展示方面，系统采用流式通信方式逐步返回诊断内容，减少长时间等待带来的交互中断。前端同步呈现用户输入、系统诊断结果以及后续作业信息，使故障描述、知识检索和检修操作保持在统一工作界面中。通过多模态信息输入与多轮交互相结合，系统为后续 RAG 检索、Agent 智能诊断和 SOP 作业执行提供统一的故障信息入

口。

2.2 RAG 与 Agent 协同诊断

为兼顾标准故障的快速响应与复杂故障的深度分析，系统构建了 RAG 直出与 LangGraph Agent 双路径诊断机制。其中，RAG 路径适用于报警代码查询、常见故障定位等相对明确的场景，通过检索维修手册、案例知识和关联信息后直接生成诊断结果；Agent 路径则面向原因不明确、需要多轮分析的复杂故障，由智能体根据当前问题自主选择检索与推理工具，逐步完成故障排查。

在 Agent 诊断过程中，系统配置了维修案例库检索、维修知识库检索、MySQL 知识图谱查询和 SOP 管理等工具。诊断时优先检索已有维修案例，当历史案例能够较好匹配当前故障时，可优先复用已有处理经验；若案例信息不足，则进一步调用维修手册与知识图谱，对故障现象、可能原因和处理方案进行关联分析，从而形成更完整的诊断依据。

通过双路径协同设计，系统既保留了 RAG 在标准问题上的响应效率，也利用 Agent 增强了复杂故障下的多步骤分析与工具调用能力，使故障处理过程由单次知识检索进一步扩展为“案例匹配、知识检索、图谱关联、诊断决策”的协同流程，并为后续 SOP 作业执行提供诊断

基础。

2.3 动态知识库与手册管理

动态知识库是系统开展故障检索与智能诊断的知识基础。系统支持对企业设备维修资料进行统一管理，目前可解析 PDF、DOCX、XLS、XLSX 等格式文件，并将不同来源的维修手册转换为统一的知识条目。同步过程中，系统完成文档解析、知识数据生成和向量索引构建，使原本分散在不同设备手册中的内容能够被后续 RAG 与 Agent 统一调用。

知识库并非一次构建后保持静态，而是支持持续更新。系统记录已同步文件及其 MD5 特征，当手册内容发生变化时可重新同步知识数据；与此同时，审核通过的维修案例以及人工修正的模型回答也能够作为动态知识加入现有知识库。同步完成后，系统统一更新知识文档、知识图谱以及 DashVector 向量索引，并保留本地 FAISS 索引作为检索支撑，从而保证新增知识能够及时进入后续诊断流程。

通过这一机制，企业知识来源从传统的维修手册进一步扩展到实际维修过程中产生的案例与人工修正结果，使系统形成“资料导入—知识处理—检索应用—维修反馈—知识更新”的持续迭代链路，增强知识库对企业真实检修场景的适应能力。

2.4 设备知识图谱与关联检索

为解决维修知识之间关联关系难以通过普通文档检索直接呈现的问题，系统在知识库基础上构建设备维修知识图谱。系统从维修资料中组织设备、部件、故障、维修文档等实体及其关联关系，将分散的文本知识转化为结构化网络，并通过前端知识图谱界面进行可视化展示。当前图谱构建过程中可识别主轴、伺服、编码器、驱动器、电源等典型设备部件，并建立设备与文档、文档与部件、文档与故障之间的关系。

知识图谱同时参与实际故障诊断。系统后端设置独立的图谱查询能力，Agent 可在复杂故障分析过程中调用 MySQL 知识图谱，根据当前故障进一步获取相关原因、解决方案和关联知识。因此，图谱在系统中既承担维修知识的结构化展示功能，也作为融合检索中的知识补充路径，使检修人员能够由单一故障信息进一步追踪相关部件和处理知识。

2.5 动态 SOP 标准化作业指引

完成故障诊断后，系统进一步将诊断结果转化为可执行的 SOP 检修流程，使智能诊断能够真正延伸至现场作业环节。SOP 根据当前故障及诊断结果组织具体检修步骤，并可包含故障确认、安全准备、初步检查、电气检查、参数检查、维修或更换、复位恢复和结果验证

等不同阶段。系统同时将操作规范、安全要求和警告信息与普通检修步骤区分处理，避免安全提示被错误作为操作步骤执行。

针对大模型多轮交互过程中可能反复生成不同操作流程的问题，系统设计了 SOP 首版冻结机制。当某一检修会话已经生成有效 SOP 后，后续对话不会随意覆盖原有步骤结构，而是在已有流程基础上更新各步骤的执行状态和现场备注。SOP 通过 MySQL 持久化保存，并按照 session_id 与具体检修会话绑定，保证不同故障任务之间的作业流程相互独立。

检修人员执行过程中，系统可记录步骤的待执行、进行中和已完成状态，并支持单步或批量更新。当全部步骤执行完成后，相应作业信息可继续进入维修报告与维修记录环节。由此，系统将大模型生成的诊断建议进一步转化为稳定、可执行、可记录和可追溯的标准化检修流程，减少多轮诊断过程中作业步骤变化带来的现场操作风险。

2.6 维修记录与知识闭环

维修记录模块负责承接故障诊断与 SOP 执行后的实际维修结果，将一次检修过程沉淀为可查询、可统计的结构化记录。系统可保存设备型号、故障类型、故障描述、故障原因、维修方案、更换配件、维修人员、维修时间及故障解决状态等信息，并支持维修记录的新增、修改、删除、分页查询以及 CSV 导出，便于后续进行故障复盘和运维

数据管理。

系统同时提供维修报告持久化功能，可将完成后的检修报告与对应工单编号关联并保存至 MySQL。管理人员能够统一查看已提交报告，一线人员也可以同步查询个人历史维修结果，使诊断过程、SOP 执行情况与最终维修结果形成连续的数据链路。

更重要的是，维修记录并非仅作为历史档案保存。系统可将有效维修记录自动转换为新的维修案例，其中包含设备型号、故障类型、故障原因、处理方案及解决结果等信息，并写入动态知识库。经过同步后，这些实际维修经验能够再次进入后续向量检索和智能诊断过程，形成“故障诊断—SOP 执行—维修记录—案例沉淀—知识复用”的闭环，使企业知识库能够随着实际检修过程持续积累和更新。

2.7 用户与权限组管理

为满足企业多人协同使用需求，系统建立了基于用户、权限组和具体权限项的访问控制机制。用户登录成功后由后端签发 JWT 身份凭证，其中包含用户所属权限组、权限列表以及管理员标识；普通用户与管理员设置不同的凭证有效周期，系统在访问受保护接口时进行身份与权限校验，从而限制知识管理、用户管理及系统配置等敏感操作。

管理端支持用户和权限组的集中维护。管理员可以新增、删除用

户，调整用户所属权限组，并针对特定用户配置额外权限；同时支持创建、编辑和删除权限组，并为不同权限组设置功能权限。系统还能够根据用户所属权限组动态统计成员，实现从基础角色划分到个体权限补充的灵活授权方式，更适合企业中不同岗位人员共同使用同一检修平台的场景。

2.8 系统运维与模型服务监控

系统设置独立的运维监控模块，为管理人员提供后端服务、知识库和模型调用状态的统一查看入口。监控页面可实时统计系统版本、运行时长、知识库文档数量、手册数量、动态知识数量以及最近同步状态，同时检查数据目录、知识目录、数据库连接和向量索引是否正常。当 DashVector 不可用或未配置时，系统还能够识别 FAISS 本地索引及关键词检索等当前可用状态，便于快速判断知识检索链路是否正常。

除基础运行状态外，模块还承担 AI 服务配置与连通性管理。系统可以测试大语言模型 API 是否可正常调用，并集中读取和维护对话模型、视觉模型、Embedding 模型以及语音相关模型的配置。管理员能够直接查看当前使用的模型和接口状态，在模型服务异常或配置发生变化时及时定位问题，降低多模型系统的日常维护成本。

2.9 移动端便捷支持

为适配现场检修环境的复杂性与一线工人移动办公的需求，系统同步开发了微信小程序端，作为桌面 Web 端的有力补充。手机 APP 端可实现核心功能的轻量化迁移，让检修人员在不便使用电脑的产线旁、设备间或户外场景下，仍能随时获取智能检修支持。

手机 APP 端聚焦以下核心能力：支持自然语言提问与故障图片拍摄上传，实现与 Web 端一致的多模态智能问答；支持会话列表查看与历史对话回溯，方便现场快速查阅此前排查记录；支持设备型号筛选，帮助工人精准定位特定机型的知识内容；同时适配手机 APP 特有的交互习惯，优化输入与图片上传流程，降低操作门槛。手机 APP 后端复用主系统的 RAG 检索与模型推理服务，确保答案质量与 Web 端保持一致，不因终端变化而折损智能水平。

手机 APP 特别适用于一线工人“边走边问”“即拍即查”的典型场景，例如在巡检途中发现异常立即拍照查询或者语音输入，或在工作间隙快速回顾以往故障处理方案。系统通过手机 APP 将智能检修能力延伸至车间最前沿，真正实现了“随时随地，智修无忧”，有效缩短了从发现问题到获取解决方案的时间窗口，进一步提升整体排障效率。手机 APP 与 Web 端数据互通，用户的会话、工单、收藏等内容可在不同终端间无缝衔接，保障业务连续性与使用便利性。

2.10 国产化适配与部署支持

为响应国家信创战略，满足制造企业对于自主可控基础设施的硬性要求，系统在架构设计与部署实施上全面适配国产化技术栈，重点完成对龙芯（LoongArch）处理器架构与银河麒麟高级服务器操作系统的兼容性验证与性能优化。

系统前后端完全基于跨平台技术构建：前端采用 Vue 3 + Vite，后端采用 Python + FastAPI，所有依赖库均选用支持国产 CPU 指令集的版本。在适配过程中，团队对向量检索（阿里云 DashVector 云端服务）等在龙芯环境下的编译与运行进行了针对性调优，确保向量检索与模型推理在国产硬件上的性能表现与 x86 架构基本持平。同时，系统支持以私有化方式部署在企业内网，所有知识数据、用户信息、工单记录均存储于本地服务器，无需上传公网，彻底消除数据出境风险，满足工业数据安全合规要求。

系统已在龙芯服务器虚拟机（银河麒麟 V11 操作系统）上完成全功能测试，涵盖多模态问答、知识图谱渲染、SOP 流程生成、工单归档、手册同步等所有核心业务场景，测试结果稳定可靠。国产化适配不仅增强了系统的安全性与可控性，也为系统在政府、军工、能源等对自主可控要求更高的行业推广奠定了坚实基础，成为本项目的核心差异化竞争力之一。

第三章 非功能需求

3.1 性能需求

系统需保障前端交互的流畅性，适配工业现场办公电脑的普遍配置。页面切换、按钮点击、图谱拖拽、步骤切换等基础操作的响应延迟需低于 200 毫秒，无明显卡顿与掉帧现象，保障操作跟手性。

检索与渲染性能需满足工业级知识库规模的使用需求。对于常规文本检索请求，知识库召回与答案生成的整体耗时控制在 5 秒以内；包含图片的多模态检索请求，整体耗时控制在 10 秒以内。知识图谱支持承载 800 多个节点与 700 多条边，页面加载时间不超过 5 秒，缩放、拖拽、悬停等交互操作流畅无明显延迟，保障可视化体验。

系统需具备良好的并发处理能力，支持至少 30 个用户同时在线进行问答交互，10 个用户同时触发手册同步任务时，核心服务无明显性能衰减，问答响应时间增幅不超过 30%。手册同步、向量构建等耗时操作采用异步任务队列处理，不阻塞主服务响应，保障高并发场景下的系统稳定性。

资源占用需保持在合理区间，适配普通办公与工业服务器环境。前端页面空载内存占用控制在 500MB 以内，开启多会话与图谱后内存占用不超过 800MB，适配普通办公电脑运行；后端服务在空载

状态下内存占用低于 2GB，单条问答请求的 CPU 峰值占用合理，支持在普通服务器甚至国产化信创服务器上稳定部署运行。

3.2 可用性需求

系统需具备优秀的易学性与易用性，贴合一线工业用户的使用习惯。界面采用工业级深色科技风格，信息层级清晰，核心功能入口突出，减少不必要的装饰元素，降低视觉干扰。无系统使用经验的用户，可在 15 分钟内掌握提问、上传图片、查看 SOP 等核心操作流程，快速上手开展工作。管理端功能分类清晰，操作路径简短，管理员可快速上手完成日常运维工作。

交互一致性与反馈机制需完善统一。全系统采用统一的设计语言与交互规范，按钮、弹窗、提示、加载动画样式保持高度一致。所有用户操作均有明确的状态反馈，加载状态、成功提示、错误警告清晰易懂，异常场景给出具体的解决指引，例如网络失败时提示“请检查后端服务是否启动”，帮助用户快速排查问题，减少无效求助。

系统需具备良好的容错性与可恢复性。前端对非法输入、超大文件、格式错误等操作均有前置校验与友好提示，不会导致页面崩溃与数据丢失。后端服务异常时，前端展示清晰的错误信息而非空白页面，保障用户知晓异常原因。用户会话数据与工单数据采用持久化存储，

页面刷新或浏览器重启后数据不丢失，可快速恢复工作状态，避免现场检修记录意外丢失。

系统需具备广泛的适配性，覆盖主流桌面环境。适配 Chrome、Edge、Firefox 等主流桌面浏览器，分辨率适配 1080P 及以上主流办公显示器。界面布局采用响应式设计，在不同尺寸屏幕下均可正常展示核心内容，无元素错位与功能缺失，适配企业内不同配置的办公终端。

3.3 可靠性需求

系统需具备工业级的运行稳定性，核心服务需支持 7x24 小时稳定运行。在持续高负载运行条件下，服务无内存泄漏、无无故崩溃、无性能明显衰减现象。异步任务具备失败重试机制，手册同步、向量构建等任务执行失败时自动重试最多 2 次，并记录详细错误日志，保障知识更新任务的最终完成率，避免因瞬时网络波动导致任务失败。

数据安全性与可靠性是工业系统的核心要求。知识库文件、用户账号、工单记录等核心数据均持久化存储在本地，支持定期自动备份机制，防止数据意外丢失。所有管理操作均经过权限校验，防止越权访问与数据篡改。系统支持完全私有化部署，所有知识数据均存储在企业本地服务器，无需上传公网，保障企业核心技术资料的安全，满足

工业数据不出域的合规要求。

系统需具备完善的服务降级能力，保障极端场景下的基础业务可用。当大模型 API 出现异常时，系统可根据配置自动切换至降级模式，基于关键词检索直接返回知识库原文内容，保障基础检索能力可用，不会因大模型服务波动导致整体系统瘫痪，为现场检修业务提供兜底保障，避免影响生产排程。

系统需具备完整的日志可追溯能力。对所有关键操作与接口请求均保留日志记录，包括用户登录、手册上传、工单提交、权限变更、系统异常等，日志包含操作人、操作时间、操作内容与结果等完整信息，便于出现问题时进行溯源排查与责任认定，符合企业信息化管理的审计要求。

3.4 可扩展性需求

AI 模型需支持可替换与可插拔设计。系统大模型调用层采用抽象化设计，通过统一的 **Provider** 工厂模式管理不同模型供应商，不与单一模型厂商深度耦合。支持通过修改配置文件快速替换大模型与向量模型，适配不同企业的模型选型需求，未来可无缝接入私有化部署的行业大模型，保障技术架构的长期生命力。

功能模块需具备良好的可扩展性。系统采用模块化架构设计，各功能模块职责边界清晰，通过标准接口进行交互。未来新增功能模块，如语音交互、AR 检修指引、设备物联网数据对接等，可在不改动核心架构的前提下进行插件式扩展，适配工业检修场景的多样化需求，保护企业前期投入。

知识库体系需支持可持续扩展。系统支持无限量新增设备手册与维修案例，向量索引与知识图谱支持增量更新，无需全量重建。文档解析模块采用注册制设计，未来可扩展支持 PPT、Excel、图片扫描件等更多类型的资料格式，持续丰富知识库的内容来源，伴随企业知识资产积累同步成长。

部署环境需具备广泛的适配能力。系统采用前后端分离架构，支持容器化部署，可根据企业规模灵活选择单机部署或分布式部署。适配 x86 通用架构与龙芯、飞腾等国产化信创架构，满足不同企业的基础设施环境要求，具备广泛的部署适配能力，可适配从中小企业到大型集团的不同规模需求。